Machine Translated by Google

Buletin Teknik Elektro dan Informatika
Vol. 11, No. 6, Desember 2022, hlm. 3570~3576
ISSN: 2302-9285, DOI: 10.11591/eei.v11i6.4353

Klasifikasi serangan DDoS berbasis pengelompokan K-Means semi-supervised

Mahdi Nsaif Jasim1 , Methaq Talib Gaata2
1Departemen Informatika Bisnis, Universitas Teknologi Informasi dan Komunikasi, Baghdad, Irak
2Departemen Ilmu Komputer, Universitas Mustansiriyah, Baghdad, Irak

Informasi Artikel

Riwayat artikel:

Diterima 4 Juli 2022
Direvisi 5 Agustus 2022
Diterima 16 Agustus 2022

Kata kunci:

CICIDS2017
Kekelompokan
Serangan penolakan layanan terdistribusi
Pemilihan fitur
Algoritma K-Means
Keamanan jaringan

ABSTRAK

Serangan jaringan berupa Distributed Denial of Service (DDoS) digunakan untuk mengganggu respons dan layanan server. Serangan ini populer karena mudah diatur dan sulit dideteksi. Kita dapat mengidentifikasi serangan DDoS pada lalu lintas jaringan dengan berbagai cara. Namun, metode yang paling efektif untuk mendeteksi dan mengidentifikasi serangan DDoS adalah pendekatan pembelajaran mesin. Serangan ini dianggap sebagai salah satu ancaman internet yang paling berbahaya. Agar algoritma pembelajaran mesin terawasi dapat berfungsi, diperlukan kumpulan data lalu lintas jaringan yang diberi label. Di sisi lain, metode tak terawasi menggunakan analisis lalu lintas jaringan untuk menemukan serangan. Dalam penelitian ini, algoritma pengelompokan K-Means dikembangkan sebagai pendekatan semi-terawasi untuk klasifikasi DDoS. Algoritma yang diusulkan dilatih dan diuji dengan dataset CICIDS2017. Setelah menggunakan metode pemilihan fitur hibrida yang diusulkan dan menerapkan beberapa pelatihan, pengujian, dan pengurutan lalu lintas DDoS secara cermat melalui serangkaian eksperimen, ditemukan 2 centroid optimal yaitu DDoS dan normal. Centroid yang dihasilkan dapat digunakan untuk mengklasifikasikan lalu lintas jaringan. Jadi, metode yang diusulkan berhasil mengelompokkan lalu lintas jaringan ke dalam kategori aman dan ancaman.

Ini adalah artikel akses terbuka di bawah lisensi CC BY-SA. lisensi.

Penulis Korespondensi:

Mahdi Nsaif Jasim
Departemen Informatika Bisnis, Universitas Teknologi Informasi dan Komunikasi
Baghdad, Irak
Email: mahdinsaif@uoitc.edu.iq

1. PENDAHULUAN

Serangan Distributed Denial of Service (DDoS) adalah bentuk serangan penolakan layanan (DoS) di mana penyerang menargetkan korban dengan memanfaatkan alamat IP pengguna yang berwenang. Berbagai serangan DDoS meliputi SYN-flood, ACK-flood, UDP-flood, DDoS koneksi, DNS reflect, dan ICMP flood, di antara lainnya. [1]. Tujuan utama serangan adalah untuk mencegah penerima yang dituju menggunakan layanan yang dituju dengan membebani sumber daya tersebut. Salah satu taktik yang digunakan penyerang untuk mencapai hal ini adalah dengan mengirimkan serangkaian permintaan palsu melalui jaringan. DDoS diluncurkan dari banyak komputer secara bersamaan. Dengan membanjiri infrastruktur yang mengelilingi aliran lalu lintas internet, serangan DoS adalah teknik jahat yang mengganggu lalu lintas dan operasi jaringan reguler dari server yang ditargetkan. Tingkat dan volume lalu lintas jaringan yang dikirim ke target sangat berkorelasi dengan tingkat keparahan serangan [2].

Sejak tahun 1990-an, sistem deteksi intrusi yang canggih telah dibuat dengan bantuan penambangan data. Teknik penambangan data secara umum, dan teknik pembelajaran mesin secara khusus, harus diterapkan dalam lima langkah: seleksi, pra-pemrosesan, transformasi, penambangan, dan interpretasi [3], [4]. Dari semua cara untuk menemukan intrusi menggunakan penambangan data, tiga langkah penting ini adalah yang paling sulit. Ada tiga jenis metode deteksi DDoS berbasis pembelajaran mesin yang sudah digunakan. Pendekatan ML terawasi yang membangun model deteksi dari kumpulan data lalu lintas jaringan yang telah dihasilkan dan diberi label. Pendekatan terawasi

Machine Translated by Google

Pendekatan ini harus mengatasi dua masalah besar. Pertama, membuat dataset lalu lintas jaringan berlabel membutuhkan banyak waktu dan daya komputasi. Tanpa pembaruan model yang konstan, teknik pembelajaran mesin terawasi tidak dapat memprediksi tindakan baru yang sekaligus aman dan berisiko. Kedua, pengklasifikasi ML terawasi tidak bekerja dengan baik ketika terdapat banyak data abnormal dalam lalu lintas jaringan. Ini disebut noise. Pada kelompok kedua, tidak diperlukan dataset berlabel untuk membangun model deteksi, yang berbeda dari kelompok pertama. Masalah utama dengan metode tak terawasi adalah menghasilkan banyak false positive. Kutukan masalah dimensionalitas [5] membuat metode tak terawasi sulit menemukan serangan secara akurat [6]. Dengan mampu bekerja pada dataset berlabel dan tak berlabel, konsep ML semi-supervised memanfaatkan teknik terawasi dan tak terawasi. Selain itu, penggunaan metode terawasi dan tak terawasi secara bersamaan dapat meningkatkan akurasi dan mengurangi jumlah false positive. Namun, masalah pada kedua pendekatan tersebut juga membuat pendekatan semi-supervised sulit untuk bekerja. Oleh karena itu, pendekatan semi-supervised perlu menggabungkan bagian-bagiannya dengan cara yang cerdas untuk mengatasi masalah yang ada pada pendekatan supervised dan unsupervised.

Sekelompok tugas dan teknik pembelajaran mesin yang dikenal sebagai "pembelajaran semi-supervised" menggabungkan sampel berlabel dengan sampel tidak berlabel untuk pelatihan, seringkali menggabungkan sejumlah kecil sampel berlabel dengan sejumlah besar sampel tidak berlabel. Pendekatan pembelajaran semi-supervised berada di tengah-tengah antara pembelajaran supervised dan unsupervised. Banyak peneliti pembelajaran mesin telah menunjukkan bahwa mengintegrasikan sejumlah kecil data berlabel dengan data tidak berlabel dapat secara dramatis meningkatkan akurasi pembelajaran dibandingkan dengan pembelajaran unsupervised tanpa waktu dan biaya yang besar seperti pada pembelajaran supervised. Aturan umum pertama kali dieksplorasi menggunakan data berlabel dalam proses pembelajaran semi-supervised, dan kemudian aturan tersebut diterapkan untuk menyimpulkan data yang tidak berl
Algoritma pembelajaran mesin yang ditingkatkan untuk deteksi intrusi [7].

Tujuan utama dari penelitian ini adalah untuk menemukan metode yang tepat untuk mengklasifikasikan serangan DDoS dengan menggunakan pembelajaran semi-supervised dan mendasarkannya pada dataset DDoS global. Selain itu, penelitian ini juga bertujuan untuk menemukan centroid yang paling efektif untuk aplikasi dalam klasifikasi serangan. Berikut adalah beberapa manfaat dari algoritma yang kami usulkan dibandingkan dengan solusi deteksi sebelumnya yang menggunakan pendekatan pembelajaran supervised dan unsupervised: i) dibutuhkan lebih sedikit sampel berlabel untuk melatih model deteksi dengan metode yang kami usulkan dibandingkan dengan algoritma deteksi pembelajaran supervised, ii) metode pemilihan fitur hibrida yang diusulkan menggunakan filter varians rendah dan teknik rasio perolehan informasi, iii) menyajikan centroid DDoS dan reguler untuk membantu implementasinya secara online untuk klasifikasi lalu lintas. Berikut adalah ringkasan dari bagian-bagian selanjutnya dari makalah ini. Karya-karya terkait dalam deteksi serangan DDoS diperkenalkan beserta keterbatasannya. Model deteksi kami, yang dibangun berdasarkan algoritma clustering semi-supervised, disajikan di bagian 2. Setelah hasil dan analisis eksperimen serta diskusi tentang signifikansinya, makalah ini diakhiri dengan rekomendasi untuk penelitian lebih lanjut. Deteksi serangan DDoS telah diusulkan menggunakan berbagai metode berbeda seperti [8]–[10]. Teknik berbasis pembelajaran mesin adalah yang paling sering muncul dalam karya penelitian yang dipublikasikan. Tabel 1 (dalam Lampiran) memberikan gambaran singkat tentang beberapa penelitian dan perkembangan terkini dalam deteksi DDoS.

2. METODE YANG DIUSULKAN Pada bagian

awal ini, dijelaskan dataset yang digunakan dalam penelitian ini. Kemudian, metode yang diusulkan untuk deteksi intrusi dan pengelompokan centroid yang diusulkan disajikan seperti yang ditunjukkan pada Gambar 1. Terakhir, hasil dianalisis dan dibahas.

2.1. Deskripsi dataset

Sharafaldin *dkk.* [21] menyarankan CICIDS2017 untuk mengatasi fakta bahwa tidak ada cukup dataset IDS yang memenuhi kriteria lalu lintas jaringan dunia nyata [22]. Dataset CICIDS2017 yang valid dan banyak digunakan [23], yang merupakan dataset terbesar dan paling banyak digunakan [24]. 20% dari dataset CICIDS2017 digunakan dalam pekerjaan saat ini untuk melatih algoritma pembelajaran mesin. Kumpulan data ini mencakup 84 fitur, serta lalu lintas tanpa serangan dan lalu lintas serangan. Dataset CICIDS2017 memiliki banyak informasi dengan ketidakseimbangan kelas yang tinggi.

2.2. Algoritma pengelompokan K-Means

Teknik kuantisasi vektor yang dikenal sebagai "k-means" mencoba mengelompokkan n observasi untuk membuat k klaster, di mana setiap observasi termasuk dalam satu klaster yang memiliki rata-rata terdekat (juga dikenal sebagai centroid klaster atau pusat klaster), yang bertindak sebagai prototipe klaster [25]. Kedua algoritma (Hierarchical clustering dan K-Means) sering menggunakan metode canopy sebagai langkah pra-pemrosesan dalam proses masing-masing.
[26]. Tujuannya adalah untuk meningkatkan kecepatan operasi pengelompokan pada kumpulan data besar, di mana penggunaan algoritma lain secara langsung mungkin tidak praktis karena volume kumpulan data tersebut.

2.3. Metode pemilihan fitur

Salah satu masalah paling umum yang dihadapi peneliti adalah memilih fitur mana yang paling penting dan relevan untuk digunakan dalam mendeteksi serangan. Pemilihan fitur sangat penting karena memengaruhi seberapa baik sistem bekerja. Terlalu sedikit fitur dapat menyebabkan akurasi deteksi yang kurang baik, sementara terlalu banyak fitur dapat menghasilkan

Machine Translated by Google

Akurasi diperoleh dengan mengorbankan sistem yang terlalu kompleks yang menghabiskan lebih banyak sumber daya. Penelitian ini menggunakan dua teknik pemilihan fitur yang menarik; Gambar 1 mewakili diagram utama kerangka kerja yang diusulkan.

2.3.1. Teknik pemilihan fitur filter varians

Metode filter varian rendah [27] digunakan untuk memilih fitur yang digunakan dalam makalah ini, karena semua atribut berupa angka. Metode ini digunakan untuk mengecualikan fitur dengan varian rendah yang memberikan kontribusi sedikit atau nol terhadap kinerja keseluruhan model. Perhitungan varian setiap karakteristik melibatkan (1).

$$(\quad ^2) = \frac{ÿ (ÿ\ÿ) \quad ^2}{} \tag{1}$$

di mana *ÿ* adalah rata-rata dari semua nilai yang terkait dengan atribut tersebut. Nilai atribut, yang dilambangkan dengan *Xi,* diambil dari kumpulan data, di mana N adalah jumlah total sampel.

2.3.2. Perolehan informasi

Karena kegunaan dan kepentingannya dalam mendeteksi tipe kelas, IGR [28] juga digunakan sebagai bobot untuk atribut dalam pekerjaan ini (2).

$$(, \quad) = \frac{( )ÿ (| \quad)}{( )} \tag{2}$$

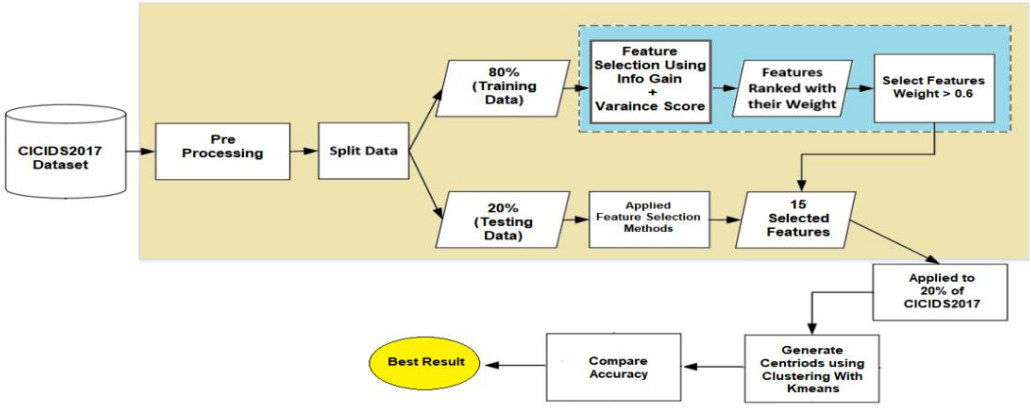
di mana *Y* mewakili kelas dan Aj adalah indeks dari *j.* th atribut. Fungsi entropi, *H (.),* didefinisikan sebagai berikut:

$$( ) = ÿÿ ( ) \quad _{=1} \quad ( ) \tag{3}$$

Dengan diberikan sebuah input, probabilitas dapat dinyatakan sebagai di mana *P(.)* mewakili operator probabilitas dan *i* mewakili indeks probabilitas.

2.4. Usulan pengelompokan centroid

Metode yang diusulkan adalah penggunaan pengelompokan K-Means semi-supervised untuk menghasilkan beberapa centroid yang dapat digunakan untuk mengklasifikasikan lalu lintas sebagai aman atau berbahaya. Dimulai dengan dataset CICIDS2017 yang dipilih, kami menggunakan algoritma K-Means untuk menghasilkan centroid semi-supervised untuk mendeteksi serangan DDoS. Gagasan semi-supervised melibatkan penggunaan sejumlah kecil data berlabel untuk tujuan memberi label pada kumpulan data yang lebih besar. Gambar 1 menunjukkan diagram kerangka kerja semi-supervised.



Gambar 1. Kerangka kerja yang diusulkan

Proses utama dalam kerangka kerja yang diusulkan diilustrasikan sebagai berikut:

a. Fitur-fitur yang dipilih menggunakan algoritma pemilihan fitur hibrida. Dalam penelitian ini, skor varians dan perolehan informasi digunakan untuk menemukan daftar fitur yang sempurna. Dengan menerapkan varians untuk mengecualikan fitur-fitur yang tidak berguna dengan skor varians kurang dari 3. Selain itu, dengan membuang fitur-fitur dengan bobot minimum 0,6 dari perolehan informasi, maka dihasilkan 15 fitur terpilih, seperti yang ditunjukkan dan tercantum dalam Tabel 2. Perhatikan nilai varians untuk semua rentang data (0 hingga 9,99E+14) untuk fitur (Bwd PSH Flags dan Fwd IAT Total) masing-masing.

b. Memanfaatkan algoritma K-Means untuk menghasilkan centroid yang sesuai. 20% dari dataset CICIDS2017 digunakan untuk melatih metode yang diusulkan untuk menghasilkan centroid, dan 80% sisanya digunakan untuk menguji centroid yang dihasilkan.

Machine Translated by Google

c. Bandingkan hasilnya dengan skor akurasi dan pilih hasil terbaik.

Tabel 2. Skor fitur menggunakan info.gain

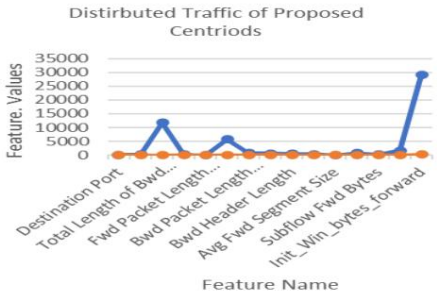
Prestasi No.	Nama Prestasi	Skor Prestasi
	SubflowFw Bytes 0.939343	
1	Total Panjang Paket yang Diteruskan 0,939343	
2	Ukuran Paket Rata-rata	0.80995
3	Panjang Total Paket Bwd 0,782456	
4	SubflowBwdBytes 0.782456	
5	BwdPacketLengthMean 0.781841	
6	Ukuran Segmen Lebar Rata-rata 0,781841	
7	Panjang Header Depan 0,778016	
8	Pelabuhan Tujuan 0.77582	
9	BwdPacketLengthMax 0.760317	
10	InitWinbytesforward 0.708411	
11	Ukuran Segmen Depan Rata-rata 0,706064	
12	Panjang Paket Rata-rata 0,706064	
13	FwdPacketLengthMax 0.701009	
14 15	BwdHeaderLength 0.682524	

3. HASIL DAN EVALUASI

Dalam percobaan ini, kinerja deteksi algoritma K-Means semi-supervised diukur.
Performa WEKA dalam pengelompokan dan pemilihan fitur berdasarkan perolehan informasi. Akurasi mengukur kemampuan algoritma untuk mendeteksi serangan baik pada lalu lintas yang tidak diserang maupun yang diserang. Akurasi dihitung berdasarkan (4).

$$\text{Ketepatan} \quad \frac{+}{+\ ++} \qquad (4)$$

Performa mesin deteksi juga dapat diukur dari akurasinya. Kemampuan mesin untuk memprediksi lalu lintas berdasarkan kondisi aktualnya ditunjukkan oleh akurasinya. Dengan kata lain, kapasitas mesin untuk mengklasifikasikan kelas secara tepat. Gambar 2 dan Tabel 3 menyajikan nilai-nilai centroid yang dihasilkan dari metode yang diusulkan. Metode ini memberikan dua centroid optimal untuk mengklasifikasikan lalu lintas menjadi normal dan serangan DDoS. Tabel 4 menampilkan performa akurasi K-Means. Hasil yang ditunjukkan pada Tabel 4 mengilustrasikan bahwa uji 1 adalah pilihan terbaik untuk mencapai akurasi dengan 2 centroid yang diberi label normal dan satu lagi dengan DDoS. Gambar 3 menyajikan perbandingan performa antara K-Means yang diusulkan dan Canopy.



Gambar 2. Distribusi lalu lintas dari centroid yang diusulkan

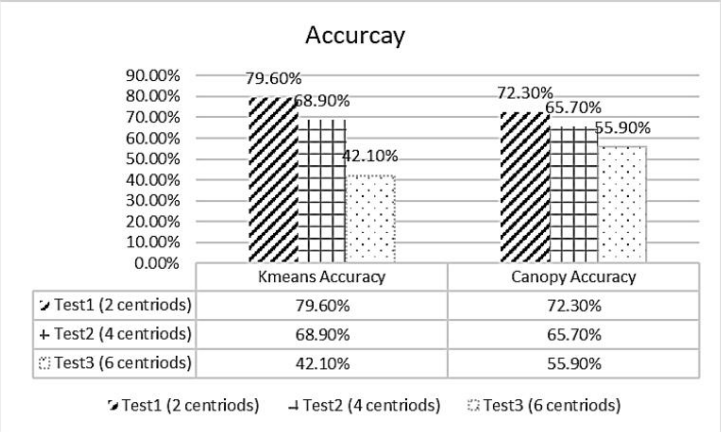
Tabel 3. Nilai centroid yang dihasilkan

No.	Fitur Nama	Centroid1 (DDoS)	Centroid2 (Normal)
	Pelabuhan Tujuan	80	80
1	2 Total Panjang Paket Maju 3 Total Panjang	288	30
	Paket Mundur 4 Panjang Paket Maju	11724	0
	Maksimum 5 Panjang Paket Maju	288	6
	Rata-rata 6 Panjang Paket Mundur	13.714286	6
	Maksimum 7 Panjang Paket Mundur	5792	0
	Rata-rata 8 Panjang Header Maju 9	732.75	0
	Panjang Header Mundur 10	680	100
	Ukuran Paket Rata-rata 11	520	0
	Ukuran Segmen Maju Rata-rata	324.648649	7.2
	12 Ukuran Segmen Mundur Rata-rata	13.714286	6
	13 Byte Mundur Subflow 14 Byte	732,75	0
	Mundur Subflow 15	288	30
	Inisialisasi_byte_kemenangan_maju	1724	0
		29200	256

Machine Translated by Google

Tabel 4. Akurasi algoritma K-Means dan canopy

Tes No.	Akurasi Keans (%) Akurasi Kanopi (%)
Tes1 (2 centroid)	79,60 72,30
Tes2 (4 centroid)	68,90 65,70
Tes3 (6 centroid)	42.10 55.90



Gambar 3. Kinerja metode yang diusulkan dan algoritma kanopi

4. KESIMPULAN DAN PEKERJAAN MASA DEPAN

Makalah ini menyajikan algoritma untuk mengklasifikasikan serangan DDoS menggunakan metode pembelajaran mesin semi-supervised. Algoritma ini dimulai dengan statistik lalu lintas yang belum diberi label, yang dikumpulkan dari tiga bagian pertahanan sisi korban, yaitu server web. Teknik pemilihan fitur hibrida yang diusulkan untuk mengurangi fitur dataset dari 84 menjadi 15 fitur digunakan untuk pelabelan akhir aliran lalu lintas dalam kerangka kerja yang diusulkan. Algoritma pengelompokan K-Means mengelompokkan data yang belum memiliki label. Skema ini menggunakan bagian representatif dari dataset benchmark CICIDS2017 dengan centroid normal dan serangan baru untuk menguji seberapa baik label diberikan. Di masa mendatang, kami ingin menemukan cara yang lebih baik untuk memberi label lalu lintas berbasis voting secara online, menambahkan lebih banyak algoritma ML ke dalam proses pengelompokan dan klasifikasi, dan memasukkan empat centroid yang diusulkan ke dalam kerangka deteksi online.

UCAPAN TERIMA KASIH

Para penulis ingin mengucapkan terima kasih kepada Universitas Teknologi Informasi dan Komunikasi serta Universitas Mustansiriyah (https://uomustansiriyah.edu.iq/), Baghdad-Irak atas dukungannya dalam penelitian ini.

LAMPIRAN

Tabel 1. Karya terkait terkini

Tidak ada referensi		Nama Teknik:	Diskusi Hasil
1	[11]	Pengelompokan Fuzzy c-means	Penelitian ini didasarkan pada karakteristik lalu lintas jaringan yang diambil dari jaringan yang mungkin mengindikasikan keberadaan botnet DDoS di jaringan tersebut. Berdasarkan hasil percobaan, tingkat deteksi mencapai sekitar 95%, dengan hanya 6% kesalahan positif.
2	[12]	Pengelompokan bersama, Informasi Rasio Penguatan, dan Ekstra-Teknik pohon dan estimasi entropi	Estimator entropi memeriksa entropi data lalu lintas jaringan selama kerangka waktu berbasis geser. Pengelompokan bersama membagi lalu lintas jaringan yang masuk menjadi tiga kelompok ketika entropi melebihi ambang batas. Rasio perolehan informasi (IGR) dihitung menggunakan entropi header jaringan rata-rata antara setiap klaster dan subset kerangka waktu saat ini. Klasifikasi ensemble Extra-Trees digunakan untuk pra-pemrosesan dan klasifikasi klaster data lalu lintas jaringan anomali dengan gain tinggi.
3	[13]	Pengelompokan Menggunakan Perwakilan (CURE), Entropi	Metode deteksi intrusi yang dijelaskan dalam artikel ini menggabungkan beberapa teknik penambangan data tanpa pengawasan. Teori entropi dalam hal pembagian jendela paket dan penambangan data diintegrasikan untuk mengidentifikasi serangan DDoS dalam aliran jaringan. Sebagai analisis klaster, digunakan pengelompokan menggunakan representatif (CURE).

Machine Translated by Google

Tabel 1. Karya terkait terkini (lanjutan)

Tidak ada referensi		Nama Teknik	Diskusi Hasil
4	[14]	Random Forest, Bagging, dan AdaboostM1	Studi ini mengusulkan model pengelompokan multi-lapisan semi-supervised (SMLC) untuk mendeteksi dan mencegah intrusi jaringan. SMLC dapat belajar dari data yang sebagian berlabel dan mencapai kinerja deteksi yang sebanding dengan IDPS berdasarkan pembelajaran mesin supervised. Kinerja SMLC pada dua dataset benchmark intrusi jaringan, NSL dan Kyoto 2006, dibandingkan dengan salah satu pendekatan semi-supervised yang terkenal (tri-training) dan model ensemble ML supervised, khususnya Random Forest, Bagging, dan Adaboost.
5	[15]	Algoritma K-Means dan Pemilihan Fitur Hibrida	Studi ini mengusulkan metode pemilihan pusat klaster awal berbasis kepadatan yang ditingkatkan setelah teknik pemilihan fitur hibrida berbasis Hadoop untuk menemukan kumpulan fitur yang paling bermanfaat, guna mengatasi masalah outlier dan optimum lokal.
6	[16]	Pendekatan verifikasi	Para peneliti menghadirkan model deteksi intrusi semi-supervised baru yang menggunakan strategi verifikasi untuk menghasilkan klasifikasi yang konsisten dari waktu ke waktu, bahkan ketika pembaruan model tidak tersedia. Model ini menggunakan pembelajaran semi-supervised untuk memperbarui model pembelajaran mesin yang mendasarinya tanpa memerlukan interaksi manusia. Verifikator kumpulan, bergantung pada kesimpulan dari kumpulan pengklasifikasi, menggunakan klasifikasi yang dikenali oleh verifikator untuk menentukan apakah klasifikasi tersebut dapat diandalkan atau tidak.
7	[17]	K-Nearest Neighbor (K-NN) dan Jaringan Saraf Buatan (ANN)	Studi ini mengusulkan FloodDetector, sebuah arsitektur efektif untuk mendeteksi serangan flooding yang dikenal dan tidak dikenal di SDN. Ini adalah aplikasi SDN yang tidak bergantung pada controller dan menggunakan dua pengklasifikasi pembelajaran mesin untuk mendeteksi serangan flooding yang dikenal dan tidak dikenal: K-nearest neighbor (K-NN) dan artificial neural network (ANN).
8	[18]	Jaringan saraf dalam	Untuk mendeteksi sistem cerdas, studi ini mengusulkan penggunaan kerangka kerja pembelajaran mesin. Studi ini menggunakan pembelajaran mendalam untuk membedakan antara pertukaran data yang tidak berbahaya dan serangan lalu lintas data yang berbahaya.
9	[19]	Generasi garis N-Gram, algoritma pemilihan fitur, dan SVM algoritma	Makalah ini menawarkan pendekatan berbasis aliran lalu lintas jaringan untuk deteksi malware seluler yang menganggap setiap aliran HTTP sebagai dokumen dan menganalisis permintaan aliran HTTP menggunakan analisis string pemrosesan bahasa alami. Model deteksi malware yang efektif dibuat menggunakan pembangkitan baris N-Gram, metode pemilihan fitur, dan algoritma SVM.
10	[20]	DBSCAN, SVM, dan Hutan Acak	Dalam makalah ini, diusulkan strategi hibrida yang diawasi/tidak diawasi. Pertama, algoritma pengelompokan memisahkan lalu lintas anomali dari data reguler dengan menggunakan berbagai kriteria berbasis aliran. Setelah menentukan karakteristik statistik yang dimiliki setiap klaster, klaster tersebut dapat diberi nama menggunakan metode kategorisasi. Para penulis melakukan evaluasi terhadap metode yang diusulkan dengan memproses sejumlah besar data.
#	Kita Diajukan	Algoritma K-Means	1- Pelatihan dan pengujian dengan dataset CICIDS2017. 2- Usulan teknik pemilihan fitur hibrida 3. Menghasilkan centroid DDoS dan centroid normal. 4- Evaluasi.

REFERENSI [1] C.

Douligeris dan A. Mitrokotsa, "Serangan DDoS dan mekanisme pertahanan: klasifikasi," *Prosiding Simposium Internasional IEEE ke-3 tentang Pemrosesan Sinyal dan Teknologi Informasi (IEEE Cat. No.03EX795),* 2003, hlm. 190-193, doi: 10.1109/ISSPIT.2003.1341092.

[2] F. Zola, L. Segurola-Gil, JL Bruse, M. Galar, dan R. Orduna-Urrutia, "Analisis lalu lintas jaringan melalui klasifikasi perilaku node: pendekatan berbasis grafik dengan pembedahan temporal dan pra-pemrosesan tingkat data," *Computers & Security,* vol. 115, hlm. 102632, April 2022, doi: 10.1016/j.cose.2022.102632.

[3] K. Kalegele, K. Sasai, H. Takahashi, G. Kitagata dan T. Kinoshita, "Empat Dekade Penambangan Data dalam Manajemen Jaringan dan Sistem," dalam *IEEE Transactions on Knowledge and Data Engineering,* vol. 27, no. 10, hlm. 2700-2716, 1 Okt. 2015, doi: 10.1109/TKDE.2015.2426713. [4]

J. Han, J. Pei, dan M. Kamber, "Penambangan data: Konsep dan teknik," *Morgan Kaufinann,* vol. 10, hlm. 559–569, 2006.

[5] S Karanam, "Kutukan Dimensi—Sebuah 'Kutukan' bagi Pembelajaran Mesin," *Towards Data Science,* [Online], Tersedia: https://towardsdatascience.com/curse-of-dimensionality-a-curse-to-machine-learning-c122ee33bfeb (Diakses 19 Juni 2022).

[6] P. Berkhin, "Sebuah survei tentang teknik penambangan data pengelompokan," dalam *Pengelompokan data multidimensi,* hlm. 25–71, 2006, doi: 10.1007/3-540-28349-8_2.

[7] RAI Alhayali, M. Aljanabi, AH Ali, MA Mohammed, dan T. Sutikno "Algoritma pembelajaran mesin yang dioptimalkan untuk deteksi intrusi," *Jurnal Teknik Elektro dan Ilmu Komputer Indonesia,* vol. 24, tidak. 1, hal.590–599, 2021, doi: 10.11591/ijeecs.v24.i1.pp590-599.

[8] MI Kareem dan MN Jasim, "Deteksi Serangan DDoS Menggunakan Algoritma Pohon Keputusan Parsial Ringan," *Konferensi Internasional Ilmu Komputer dan Rekayasa Perangkat Lunak (CSASE)* 2022, hlm. 362-367, doi: 10.1109/CSASE51777.2022.9759824.

[9] MI Kareem dan MN Jasim, "Model klasifikasi cepat dan akurat untuk serangan penolakan layanan dengan menggunakan pembelajaran mesin," *Buletin Teknik Elektro dan Informatika,* vol. 11, no. 3, hlm. 1742–1751, 2022, doi: 10.11591/eei.v11i3.3688.

[10] MI Kareem dan MN Jasim, "Tren Terkini Deteksi DDoS di Lingkungan SDN," *Teknologi Informasi ke-2 tahun 2021 Untuk Meningkatkan Pembelajaran Elektronik dan Aplikasi Lainnya (IT-ELA),* 2021, hlm. 29-34, doi: 10.1109/IT-ELA52201.2021.9773744.

[11] S. Lysenko, O. Savenko, dan K. B-kova, "Teknik Deteksi Botnet DDoS Berdasarkan Penggunaan Klaster Fuzzy C-Means Semi-Supervised," dalam *Lokakarya ICTERI,* 2018, hlm. 688–695.

Machine Translated by Google

[12] M. Idhammad, K. Afdel, dan M. Belouch, “Pendekatan pembelajaran mesin semi-supervised untuk deteksi DDoS,” *Applied Intelligence,* jilid. 48, tidak. 10, hal.3193–3208, 2018, doi: 10.1007/s10489-018-1141-2.
[13] W. Bhaya dan M. EbadyManaa, "Pendekatan deteksi serangan DDoS menggunakan analisis klaster yang efisien dalam skala data besar," *Konferensi Tahunan Tren Baru dalam Aplikasi Teknologi Informasi & Komunikasi (NTICT) 2017,* 2017, hlm. 168-173, doi: 10.1109/NTICT.2017.7976110.

[14] OYA -Jarrah, YA -Hammdi, PD Yoo, S. Muhaidat, dan M. Al-Qutayri, “Model pengelompokan multi-lapisan semi-supervised untuk deteksi intrusi,” *Komunikasi dan Jaringan Digital,* vol. 4, no. 4, hlm. 277–286, 2018, doi: 10.1016/j.dcan.2017.09.009.
[15] Y. Gu, K. Li, Z. Guo dan Y. Wang, "Metode Deteksi DDoS K-Means Semi-Supervised Menggunakan Pemilihan Fitur Hibrida Algoritma," dalam *IEEE Access,* vol. 7, hlm. 64351-64365, 2019, doi: 10.1109/ACCESS.2019.2917532.
[16] EK Viegas, AO Santin, VV Cogo dan V. Abreu, "Model Deteksi Intrusi Semi-Supervised yang Andal: Anomali Lalu Lintas Jaringan Selama Satu Tahun," *ICC 2020 - Konferensi Internasional IEEE tentang Komunikasi (ICC),* 2020, hlm. 1-6, doi: 10.1109/ICC40277.2020.9148916.

[17] SY Khamaiseh, A. Al-Alaj dan A. Warner, "FloodDetector: Mendeteksi Serangan Flooding DoS yang Tidak Dikenal di SDN," *Konferensi Internasional Internet of Things dan Aplikasi Cerdas (ITIA) 2020,* 2020, hlm. 1-5, doi: 10.1109/ITIA50152.2020.9312310.

[18] AA Ojugo dan RE Yoro, “Membangun kerangka kerja deteksi intrusi jaringan saraf pembelajaran mendalam untuk mengatasi serangan penolakan layanan terdistribusi,” *Jurnal Internasional Teknik Elektro dan Komputer (IJECE),* vol. 11, no. 2, hal. 1498, 2021, doi: 10.11591/ijece.v11i2.pp1498-1509.

[19] SR Akula, “Pendekatan pembelajaran mesin semi-supervised untuk deteksi DDOS,” *Jurnal Internasional Penelitian Inovatif Pendidikan,* vol. 8, no. 1, hlm. 27–35, 2021, doi: 10.18844/ijire.v8i1.6445.
[20] M. Najafimehr, S. Zarifzadeh, dan S. Mostafavi, “Pendekatan pembelajaran mesin hibrida untuk mendeteksi serangan DDoS yang belum pernah terjadi sebelumnya,” *Jurnal Supercomputing,* vol. 78, hlm. 8106-8136, 2022, doi: 10.1007/s11227-021-04253-x.
[21] I. Sharafaldin, A. Gharib, AH Lashkari, dan A. Ghorbani, “Menuju kumpulan data benchmark deteksi intrusi yang andal,” *Komputer Sains,* vol. 2018, no. 1, hlm. 177–200, 2017, doi: 10.13052/JSN2445-9739.2017.009.
[22] I. Sharafaldin, AH Lashkari, dan AA Ghorbani, “Menuju pembuatan dataset deteksi intrusi baru dan karakterisasi lalu lintas intrusi,” *Konferensi Internasional ke-4 tentang Keamanan dan Privasi Sistem Informasi,* vol. 1, hlm. 108–116, 2018, doi: 10.5220/0006639801080116.

[23] “Institut Keamanan Siber Kanada,” UNB, [Online], Tersedia: https://www.unb.ca/cic/datasets/ids-2017.html (Diakses 16 Juni 2022).
[24] A. Ahmim, L. Maglaras, MA Ferrag, M. Derdour dan H. Janicke, "Sistem Deteksi Intrusi Hierarkis Baru Berdasarkan Pohon Keputusan dan Model Berbasis Aturan," *Konferensi Internasional ke-15 tentang Komputasi Terdistribusi dalam Sistem Sensor (DCOSS),* 2019, hlm. 228-233, doi: 10.1109/DCOSS.2019.00059.

[25] M. Alian dan G. Al-Naymat, “Pengelompokan pertanyaan menggunakan pengelompokan canopy-K-means dan hierarchical-K-means,” *Internasional Jurnal Teknologi Informasi,* hlm. 1–10, 2022, doi: 10.1007/s41870-022-01012-w.
[26] U. Kumar, A. Dasgupta, LSNVV Krishna dan PK Chintakunta, “Menuju Deteksi dan Ekstraksi Kanopi Pohon Semi-supervised dari Citra UAV,” *Communications in Computer and Information Science,* vol. 1568, doi: 10.1007/978-3-031-11349-9_26.
[27] R. Silipo, I. Adae, A. Hart, dan M. Berthold, “Tujuh Teknik untuk Pengurangan Dimensi,” *Terbuka untuk Inovasi KNIME,* 2014.
[28] JR Quinlan, “Induksi pohon keputusan,” *Pembelajaran Mesin,* vol. 1, no. 1, hlm. 81–106, 1986, doi: 10.1007/BF00116251.

BIOGRAFI PENULIS



Mahdi Nsaif Jasim adalah Asisten Profesor Dr. Mahdi Nsaif Jasim, Universitas Teknologi Informasi dan Komunikasi, Fakultas Informatika Bisnis, Departemen Sistem Informasi Manajemen. Lahir di Babylon, Irak, tinggal di Baghdad. Minat: sistem informasi, keamanan data dan informasi, penambangan data vektor, GIS, sistem basis data. Peneliti ini tertarik pada akuisisi data dan pengolahan data SDN. Ia juga telah membimbing sejumlah mahasiswa PhD dan MSc di berbagai universitas di Irak. Dr. Mahdi telah membimbing 10 mahasiswa MSc dan 5 mahasiswa PhD. Ia mengajar sejumlah mata kuliah S1 dan S2 di beberapa universitas di Irak. Ia dapat dihubungi melalui email: mahdimnsaif@uoitc.edu.iq.



Methaq Talib Gaata adalah Asisten Profesor di Fakultas Sains, Universitas Mustansiriyah, Irak. Beliau memegang gelar PhD di bidang Ilmu Komputer dengan spesialisasi keamanan informasi. Bidang penelitiannya meliputi penyembunyian informasi, pengolahan multimedia, biometrik, pengenalan pola, dan jaringan komputer. Beliau menjabat sebagai Kepala Departemen Ilmu Komputer dari tahun 2016 hingga 2020. Saat ini, beliau menjabat sebagai Wakil Dekan Bidang Urusan Ilmiah dan Studi Pascasarjana di Fakultas Sains. Beliau telah menerima banyak penghargaan ilmiah dari Kementerian Pendidikan Tinggi dan Penelitian Ilmiah Irak. Beliau telah membimbing dan menjadi salah satu pembimbing lebih dari 25 mahasiswa magister dan 5 mahasiswa doktoral. Beliau telah menulis atau menjadi salah satu penulis lebih dari 30 publikasi dalam prosiding dan jurnal, dengan indeks H 5. Beliau dapat dihubungi melalui email: dr.methaq@uomustansiriyah.edu.iq.